

# Aula de hoje

1



**Aula sobre**

**Introdução à Inferência  
Estatística**

**Distribuição da Média  
Amostral**

**Uso do TLC**



**1º: uso do notebook**

**Aula18\_TLC\_interativo-vf**

**2º: uso do notebook**

**Aula18\_Atividade**

**3º: uso do notebook**

**Aula18\_Exercício**



Insper

# Ciência dos dados

Teorema do Limite Central

- TLC


**Inferência Estatística** é a área da estatística que contém métodos usados para tomar decisões usando uma amostra e tirar conclusões acerca de *populações*.

# Motivação – Satisfação de clientes

4

PESQUISA DE SATISFAÇÃO DO CLIENTE: COMO ELA PODE AJUDAR SUA LOJA DE ROUPAS

9 DE JULHO DE 2018 | DICAS, LOJISTAS



“Como empreendedor, é do seu interesse que sua **loja de roupas** permaneça em constante desenvolvimento. Isso significa atrair e reter os clientes, qualificar a sua equipe e vender mais.”

<https://www.brixjeans.com.br/blog/pesquisa-de-satisfacao-do-cliente/>

# Motivação – Satisfação de clientes

5

Uma rede de lojas do setor de vestuário, com lojas nos principais shoppings do Brasil, com centenas de milhares de clientes, deseja avaliar a satisfação média de seus clientes.

Você foi contratado para avaliar essa satisfação. Como você faria isso?

Uma rede de lojas do setor de vestuário, com lojas nos principais shoppings do Brasil, com centenas de milhares de clientes, deseja avaliar a satisfação média de seus clientes.

Você foi contratado para avaliar essa satisfação. Como você faria isso?

Qual a variável de interesse?

*X : nível de satisfação, **de cada** cliente da rede de lojas*

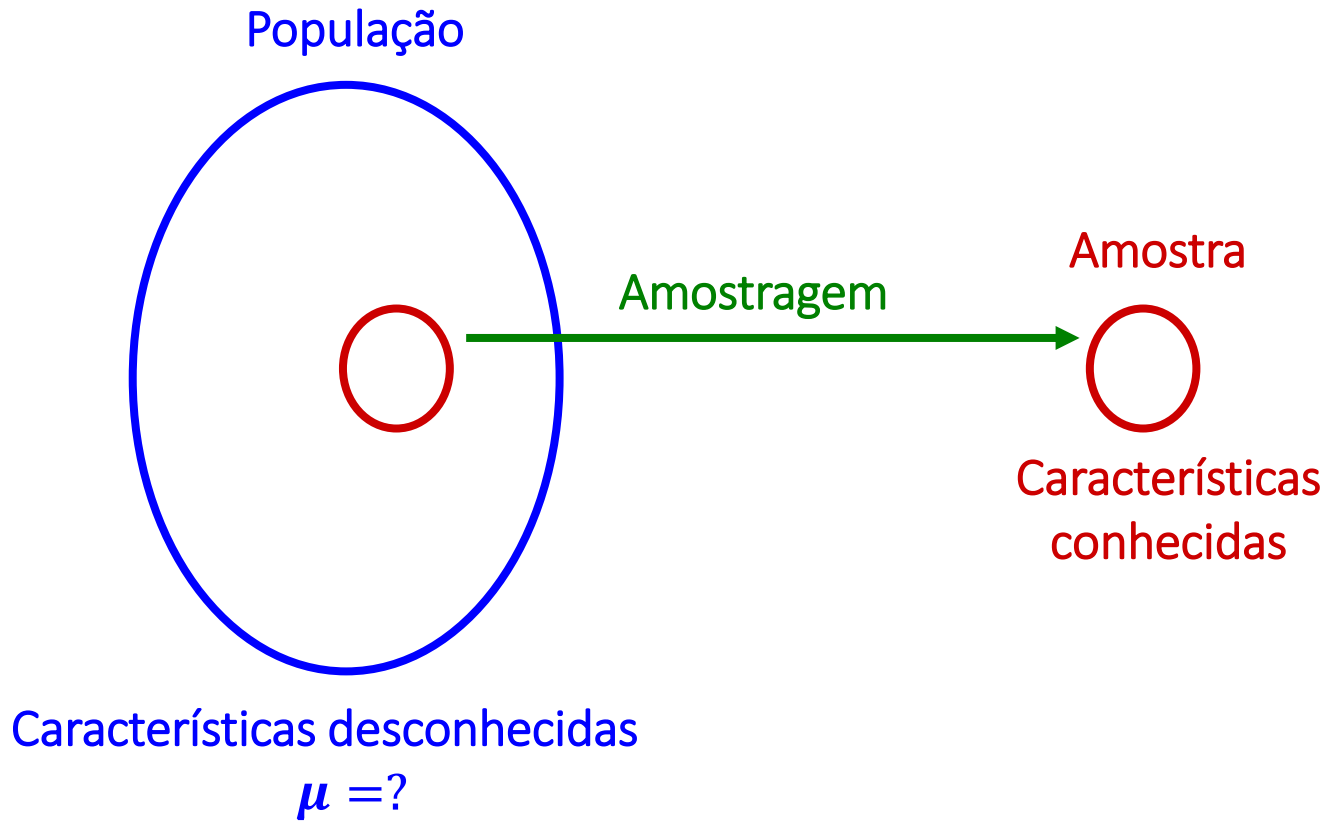
Uma rede de lojas do setor de vestuário, com lojas nos principais shoppings do Brasil, com centenas de milhares de clientes, deseja avaliar a satisfação média de seus clientes.

Você foi contratado para avaliar essa satisfação. Como você faria isso?

Qual o objetivo da pesquisa?

*Determinar o nível médio de satisfação, da população dos clientes da rede de lojas*

*$\mu$  : nível médio de satisfação da população de clientes da rede de lojas.*





# Amostra com $n = 5$

1º cliente da amostra – Satisfação = 74

2º cliente da amostra – Satisfação = 72

3º cliente da amostra – Satisfação = 74

4º cliente da amostra – Satisfação = 68

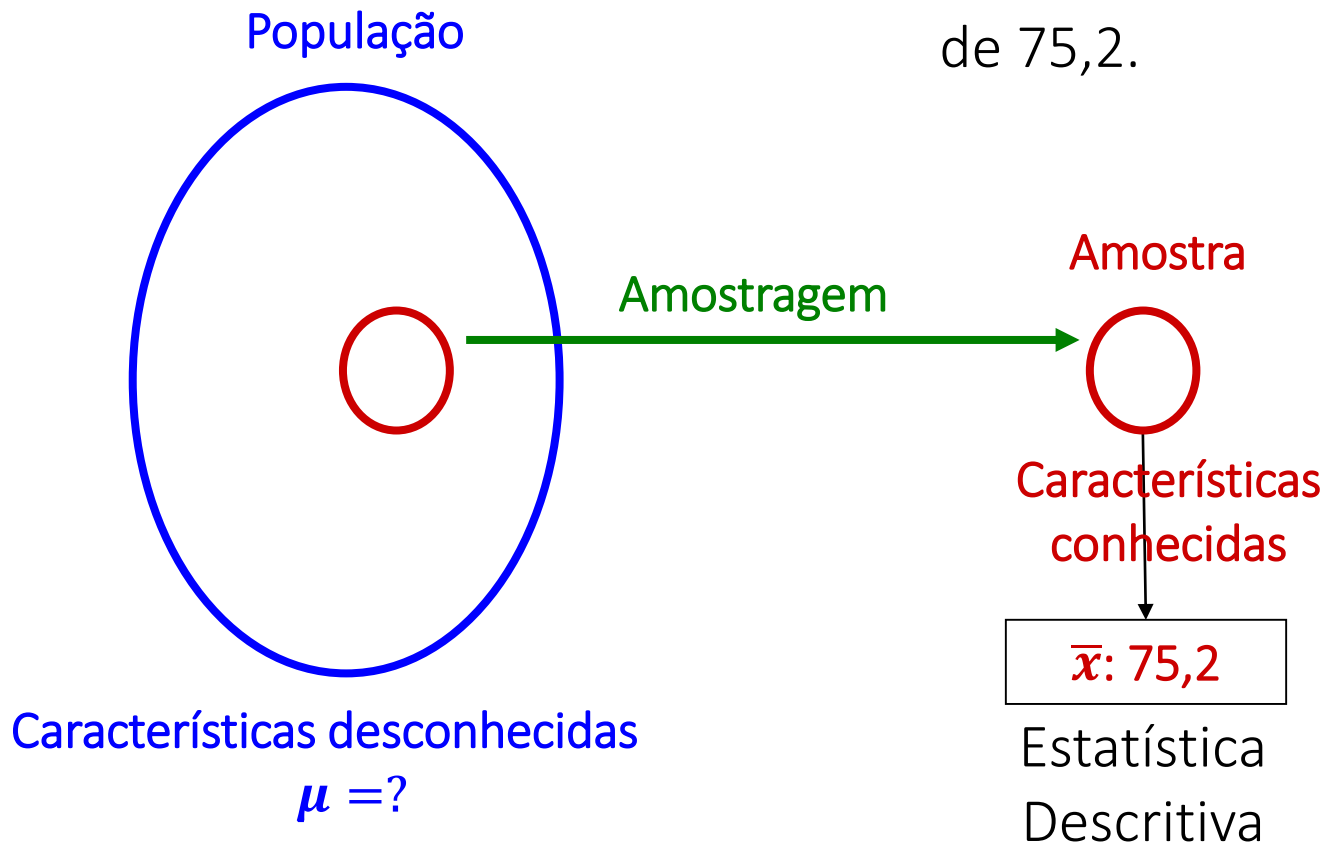
5º cliente da amostra – Satisfação = 88

Como obtenho informações sobre  $\mu$  a partir da amostra?

$$\bar{x} = \frac{74 + 72 + 74 + 68 + 88}{5} = 75,2$$

# Satisfação

Foi extraída uma amostra de 5 clientes, obtendo-se uma média de 75,2.



# Amostra com $n = 5$

## Perguntas:

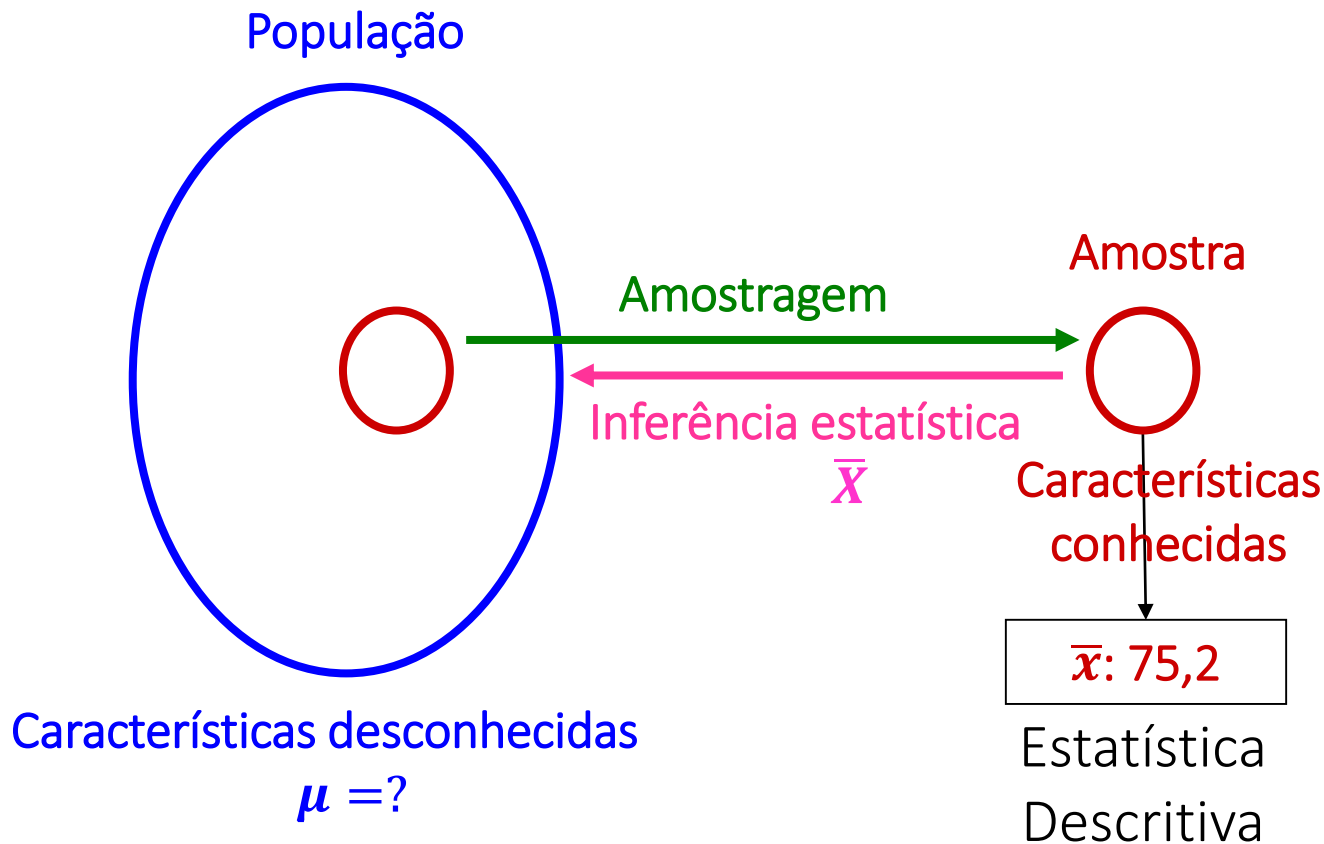
- $\bar{x}$  gera conhecimento sobre  $\mu$ ?
- $\mu$  vale exatamente o valor de  $\bar{x}$  ?
- Se outra pessoa selecionar 5 clientes dessa população, então  $\bar{x}$  também vale 75,2?
- Nesse caso, a partir de uma amostra de 5 clientes dessa população, a média amostral pode ser considerada uma variável aleatória?

Como obtenho informações sobre  $\mu$  a partir da amostra?

$$\bar{x} = \frac{74 + 72 + 74 + 68 + 88}{5} = 75,2$$

# Satisfação

Qual a relação  
entre  $\bar{x}$  e  $\mu$ ?



# Parâmetro e Estimador

13

**Parâmetro:** quantidade populacional, em geral, desconhecida.

No caso,

$\mu$ : satisfação média da população de clientes

**Estimador:** conta (função da amostra) que se faz para estimar o valor do parâmetro. No caso:

$$\bar{X} = \frac{\sum X_i}{n}$$

**Estimativa:** valor do estimador para uma particular amostra.

No caso:

$$\bar{x} = 75,2$$

# 1 amostra com $n = 5$

	A	B
1	<b>Amostra</b>	<b>1</b>
2	<b>1o cliente</b>	74
3	<b>2o cliente</b>	72
4	<b>3o cliente</b>	74
5	<b>4o cliente</b>	68
6	<b>5o cliente</b>	88
7		
8		
9		
10		
11		
12		
13		
14		
15		
16		
17		

# 1000 amostras com $n = 5$

15

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	Amostra	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
2	1o cliente	74	60	73	71	70	71	67	74	76	79	70	80	80	75	71
3	2o cliente	72	82	54	82	59	79	67	69	76	67	66	78	76	66	62
4	3o cliente	74	92	61	84	54	81	66	75	70	60	80	78	56	78	64
5	4o cliente	68	66	61	84	61	77	60	71	65	78	74	73	77	69	58
6	5o cliente	88	79	82	75	68	70	58	81	74	64	68	63	69	76	73
7																
8																
9																
10																
11																
12																
13																
14																
15																
16																
17																

# 1000 amostras com $n = 5$

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	<b>Amostra</b>	<b>1</b>	<b>2</b>	<b>3</b>	<b>4</b>	<b>5</b>	<b>6</b>	<b>7</b>	<b>8</b>	<b>9</b>	<b>10</b>	<b>11</b>	<b>12</b>	<b>13</b>	<b>14</b>	<b>15</b>
2	<b>1o cliente</b>	74	60	73	71	70	71	67	74	76	79	70	80	80	75	71
3	<b>2o cliente</b>	72	82	54	82	59	79	67	69	76	67	66	78	76	66	62
4	<b>3o cliente</b>	74	92	61	84	54	81	66	75	70	60	80	78	56	78	64
5	<b>4o cliente</b>	68	66	61	84	61	77	60	71	65	78	74	73	77	69	58
6	<b>5o cliente</b>	88	79	82	75	68	70	58	81	74	64	68	63	69	76	73
7																
8	<b>média amostral</b>	75,2	75,8	66,2	79,2	62,4	75,6	63,6	74,0	72,2	69,6	71,6	74,4	71,6	72,8	65,
9																
10																
11																
12																
13																
14																
15																
16																
17																
18																



# Estatísticas e distribuições amostrais

Uma **estatística** é qualquer função baseada nas observações de uma amostra aleatória.

Usamos estatísticas quando, para fins práticos, não é possível ter acesso as informações de toda uma população.

A distribuição de probabilidades de uma estatística é chamada de **distribuição amostral**.

# TLC\_Interativo

- Download do notebook
- Fazer individual e discutir em grupo
- Usar arquivo:

`Aula18_TLC_interativo.ipynb`

# O que TLC\_Interativo está fazendo?

19

Para mexer nesse arquivo, entenda que:

- A escolha da **distribuição** representa a distribuição da sua variável de interesse  $X$ .
- O valor de **n** representa o tamanho da sua amostra.


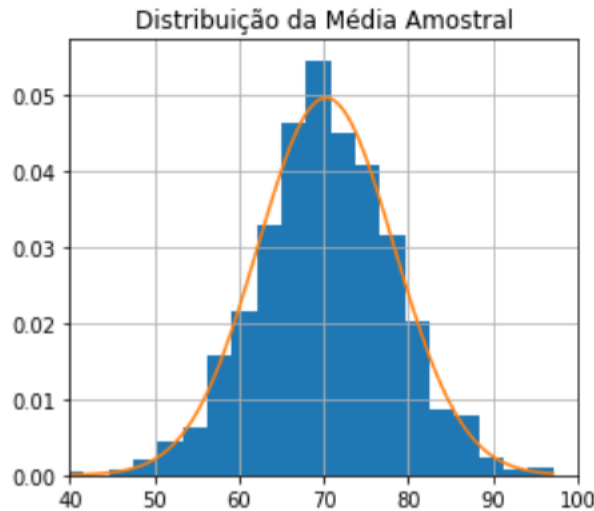
distribuição  ✓

n  1

# O que TLC\_Interativo está fazendo?

20

Para mexer nesse arquivo, entenda que os gráficos construídos apresentam a **distribuição das médias amostrais** calculadas com amostra do valor de **n** escolhido.



# O que TLC\_Interativo está fazendo?

Por fim, os valores abaixo representam:

- Primeira linha mostra média de  $X$  e de  $\bar{X}$
- Segunda linha mostra variância de  $X$  e de  $\bar{X}$

```
('CONCLUSÃO DA SIMULAÇÃO:',  
' Quando a média populacional for  $E(X)=70.500$ , então a média das médias amostrais será  $E(\bar{X})=70.529$  ',  
' Quando a variância populacional for  $Var(X)=64.000$ , então a variância das médias amostrais será  $Var(\bar{X})=67.488$ ')
```

# O que TLC\_Interativo está fazendo?

Alterando as possíveis distribuições para  $X$  e também mexendo no valor de  $n$ , qual a sua conclusão em termos de:

- Distribuição
- Média e
- Variância

para média amostral  $\bar{X}$ .

## Faça as suas conclusões.

# Processo Interativo –

## Quando $X \sim \text{Normal}$ $\rightarrow \bar{X} \sim \text{Normal}$

INPUT DA SIMULAÇÃO:

Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:


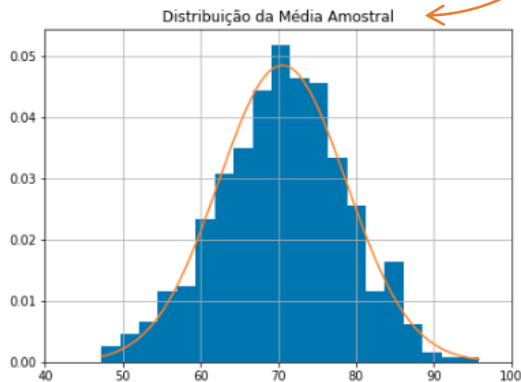
distribuição  ▼

n  1

$\bar{X}$  é normal  
quando n é pequeno

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{norm}$  com tamanho da amostra igual a 1, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

' Quando a média populacional for  $E(X)=70.500$ , então a média das médias amostrais será  $E(\bar{X})=70.529$  ',  
' Quando a variância populacional for  $\text{Var}(X)=64.000$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=67.488$ ')

# Processo Interativo –

## Quando $X \sim \text{Normal}$ $\Rightarrow \bar{X} \sim \text{Normal}$

INPUT DA SIMULAÇÃO:

Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:



distribuição  ▼

n

$\bar{X}$  é normal  
quando n é grande

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{norm}$  com tamanho da amostra igual a 50, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

- ' Quando a média populacional for  $E(X)=70.500$ , então a média das médias amostrais será  $E(\bar{X})=70.456$  ',
- ' Quando a variância populacional for  $\text{Var}(X)=64.000$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=1.240$  ')



# Distribuição amostral da média

$$X \sim \text{Normal} \xRightarrow{\text{exata}} \bar{X} \sim \text{Normal}$$

Assuma que  $X$  seja uma variável aleatória com média  $\mu$  e variância  $\sigma^2$ , ou seja,  $E(X) = \mu$  e  $Var(X) = \sigma^2$ .

Dado  $X_i$  uma variável aleatória *i.i.d.* (independente e identicamente distribuída) a  $X$  com distribuição **normal**, tem-se que:

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\sum_{i=1}^n X_i}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

para qualquer  $n$ , essa distribuição é exata normal.

# Processo Interativo –

## Quando $X \sim \text{Uniforme}$ $\Rightarrow \bar{X} \sim ?$

INPUT DA SIMULAÇÃO:


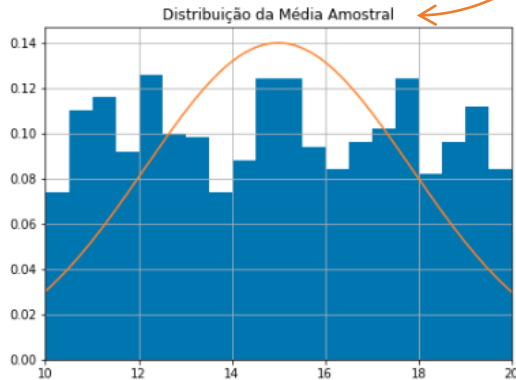
Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:

distribuição    
 n  1

$\bar{X}$  não se aproxima da normal quando n é pequeno

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{uniform}$  com tamanho da amostra igual a 1, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

' Quando a média populacional for  $E(X)=15.000$ , então a média das médias amostrais será  $E(\bar{X})=14.990$  ',  
 ' Quando a variância populacional for  $\text{Var}(X)=8.333$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=8.105$ ')

# Processo Interativo –

## Quando $X \sim \text{Uniforme}$ $\Rightarrow \bar{X} \sim ?$

INPUT DA SIMULAÇÃO:

Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:



distribuição

n

$\bar{X}$  se aproximada normal  
quando n é grande

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{uniform}$  com tamanho da amostra igual a 50, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

' Quando a média populacional for  $E(X)=15.000$ , então a média das médias amostrais será  $E(\bar{X})=15.039$  ',  
' Quando a variância populacional for  $\text{Var}(X)=8.333$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=0.163$ ')

# Processo Interativo –

## Quando $X \sim \text{Exponencial}$ $\rightarrow \bar{X} \sim ?$

28

INPUT DA SIMULAÇÃO:

Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:



distribuição

n

$\bar{X}$  não se aproxima da normal quando n é pequeno

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{expon}$  com tamanho da amostra igual a 1, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

' Quando a média populacional for  $E(X)=1.000$ , então a média das médias amostrais será  $E(\bar{X})=1.019$  ',  
' Quando a variância populacional for  $\text{Var}(X)=1.000$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=0.990$ ')

# Processo Interativo –

## Quando $X \sim \text{Exponencial} \rightarrow \bar{X} \sim ?$

29

INPUT DA SIMULAÇÃO:

Escolha a distribuição da variável de interesse X e um valor para o tamanho da amostra:


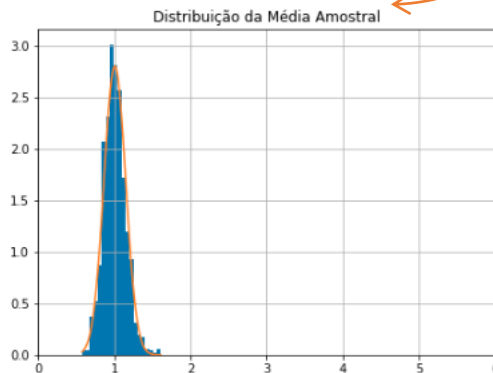
distribuição

n

$\bar{X}$  se aproximada normal  
quando n é grande

OUTPUT DA SIMULAÇÃO:

Quando  $X \sim \text{expon}$  com tamanho da amostra igual a 50, analise a distribuição da média amostral:



('CONCLUSÃO DA SIMULAÇÃO:',

- ' Quando a média populacional for  $E(X)=1.000$ , então a média das médias amostrais será  $E(\bar{X})=1.008$  ',
- ' Quando a variância populacional for  $\text{Var}(X)=1.000$ , então a variância das médias amostrais será  $\text{Var}(\bar{X})=0.020$  ')

# Distribuição amostral da média

$$X \sim ? \stackrel{TLC}{\implies} \bar{X} \sim Normal$$

## Teorema do Limite Central:

Assuma que  $X$  seja uma variável aleatória com média  $\mu$  e variância  $\sigma^2$ , ou seja,  $E(X) = \mu$  e  $Var(X) = \sigma^2$ .

Dado  $X_i$  uma variável aleatória *i.i.d.* (independente e identicamente distribuída) a  $X$  com distribuição **qualquer**, tem-se que:

$$\bar{X} = \frac{X_1 + X_2 + \dots + X_n}{n} = \frac{\sum_{i=1}^n X_i}{n} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

quando  $n$  for suficientemente grande.

*Obs:* Em alguns casos específicos, pode-se considerar  $X_i$  com distribuições diferentes ou com certa dependência entre elas.